

Ementa da Prova de CIENTISTA DE DADOS

PROGRAMAÇÃO

- Fluência na sintaxe básica
- Métodos e pacotes para leitura e escrita de dados
- Fluência nos principais pacotes de machine learning
- SKLearnv

ESTATÍSTICA BÁSICA

- Variáveis aleatórias, contínuas e discretas
- Função densidade de probabilidade e distribuição acumulada
- Propriedades de distribuições: médias, medianas, quartis, moda, variância etc.
- Testes de hipóteses
- Principais distribuições: Normal, Bernoulli, Binomial, Uniforme, Poisson, Geométrica

ÁLGEBRA

- Matrizes e vetores
- Álgebra matricial
- Distâncias e produto interno

AVALIAÇÃO DE MODELOS

- Métricas de avaliação de modelo: KS, Gini, AUC, RMSE, MAE, F1, Recall, Precision, R2
- Validações holdout, leave one out, k-fold, out of sample, out of time

DATA PREP

- Tratamento de missings
- Tratamento de Outliers
- Categorização de variáveis contínuas e discretas
- PCA
- Seleção de variáveis
- Correlação/Associação entre dados contínuos e entre dados discretos

BANCO DE DADOS

- Modelo de banco de dados relacional
- Sintaxe SQL
- Álgebra relacional: Join, group by, order by etc.
- Chaves primárias, secundárias e estrangeiras

AGRUPAMENTO

- K-means / K-medoids
- DBSCAN
- Algoritmos hierárquicos
- Estratégias para definição do número de clusters (joelho, silhueta, distância intra-cluster etc.)
- Gaussian Mixture Models (GMM)

CLASSIFICAÇÃO

- Árvore de classificação
- Random forest
- Regressão logística
- KNN
- Naive bayes (Gaussiano x Bernouli)
- Redes neurais
- SVM
- Estratégias de boosting: Gradient Boosting, ADA Boosting etc

REGRESSÃO

- Regressão linear
- Regularização L1 e L2
- Árvore de regressão
- Análise de resíduos
- Modelos lineares generalizados (GLM)

OUTROS FUNDAMENTOS

- Hadoop e Hive
- Spark e PySpark
- Redes complexas e teoria de grafos
- Ensemble modeling
- Análise de séries temporais
- Detecção de anomalia
- Text missing
- Deep learning e Tensor Flow
- Reconhecimento de Imagens
- Speech Analytics

Ementa da Prova de CIENTISTA DE DADOS

IA GENERATIVA

- Conceitos fundamentais de IA Generativa
- Conceitos fundamentais de NLP
- Arquitetura transformer
- In Context Learning
- Rags e bancos de dados vetoriais
- Técnicas de engenharia de Prompts
- Técnicas de treinamento e fine tuning
- Quantization
- Embeddings
- RLHF
- Safeguards e Guardrails

PESQUISA OPERACIONAL

- Modelos de Programação Linear: Mix de produção, Mistura, Transporte.
- Solução em Programação Linear: Gráfica e Simplex

PROGRAMAÇÃO INTEIRA

- Variáveis Inteiras e Binárias, Otimização Discreta
- Relaxação Linear
- Arredondamento
- Método Branch-and-bound

MIP (Mixed Integer Program)

- O que é?
- GAP e Best Bound
- Solvers