

MODELOS DE REGRESSÃO

1) Explique a Regressão Linear passando pelo tipo de modelo, objetivo que ela busca atender, estimação dos coeficientes e mudanças do modelo quando o objetivo é inferência e predição.

Resposta:

A regressão linear é um modelo estatístico do tipo paramétrico, usado para estimar a relação linear entre uma variável dependente contínua (target) e uma ou mais variáveis independentes (features). O objetivo central é prever valores da variável alvo ou entender como as features impactam o target.

- **Inferência:** Foco em interpretar os coeficientes; queremos saber o efeito de cada variável independente no target, mantendo os outros fixos.
- **Predição:** Foco em minimizar o erro das previsões; aceitam-se possíveis vieses nos coeficientes em troca de melhor desempenho preditivo.
- **Estimação dos coeficientes:** Geralmente é feita pelo método dos mínimos quadrados ordinários (OLS), que minimiza a soma dos quadrados dos resíduos (diferença entre valor real e previsto).
- **Mudança conforme objetivo:** Para inferência, prioriza-se modelo simples, interpretável, sem multicolinearidade. Para predição, pode-se usar regularização (Ridge/Lasso) para melhor performance, mesmo sacrificando alguma interpretabilidade.

2) Qual a diferença de um modelo paramétrico e um não paramétrico?

Resposta:

- **Modelos paramétricos** assumem uma forma funcional fixa (ex: linear, logística), definida por um número finito de parâmetros. Exemplo: regressão linear (coeficientes beta), regressão logística.
 - **Vantagem:** Treinamento eficiente, interpretabilidade.
 - **Limitação:** Falta de flexibilidade se o relacionamento real for complexo.
- **Modelos não paramétricos** não assumem uma forma funcional fixa e podem crescer em complexidade conforme mais dados são disponibilizados (ex: kNN, árvores de decisão, Random Forest).
 - **Vantagem:** Capturam relações complexas.
 - **Limitação:** Podem sofrer overfitting e são menos interpretáveis.

3) A única forma de um modelo ser paramétrico é na presença de coeficientes/parâmetros ou existe outra possibilidade?

Resposta:

Não. Ser paramétrico não depende apenas de ter coeficientes, mas de assumir uma estrutura funcional pré-definida (a relação entre X e Y segue um formato fixo, ex: linear). Um modelo pode ter parâmetros, mas ser não-paramétrico se esses parâmetros crescem com o número de dados ou não definem uma estrutura fixa (ex: árvore de decisão, número de nós cresce conforme dados).

4) Quais as premissas de um modelo de regressão focado na inferência e me elenque os motivos de cada premissa ser importante tanto para regressão linear e regressão logística

Resposta:

Premissas:

1. **Linearidade:** Relação linear entre X e Y (ou $\text{logit}(Y)$ para logística).
2. **Independência dos erros:** Resíduos não correlacionados.
3. **Homoscedasticidade:** Variância constante dos erros.
4. **Normalidade dos resíduos:** Importante para testes estatísticos de inferência (intervalo de confiança, hipóteses).
5. **Ausência de multicolinearidade:** Features não altamente correlacionadas.

Importância:

Essas premissas garantem estimadores não viesados, intervalos de confiança corretos e testes de hipóteses válidos. Na logística, normalidade dos resíduos não é obrigatória, mas independência e linearidade do logit são cruciais.

5) Qual a diferença de um estimador e uma estimativa e como provar que meu estimador é consistente em um modelo de regressão

Resposta:

- **Estimador:** Função/método para calcular um parâmetro com base em dados amostrais.
- **Estimativa:** Valor numérico obtido pelo estimador em um conjunto de dados específico.
- **Consistência:** Um estimador é consistente se, conforme o número de dados cresce, ele converge para o valor verdadeiro do parâmetro.
 - *Prova (simplificada):* Mostrar que viés $\rightarrow 0$ e variância $\rightarrow 0$ quando $n \rightarrow \infty$, usando propriedades dos mínimos quadrados.

6) Explique o ajuste dos parâmetros com base no Gradiente Descendente e Método dos Mínimos Quadrados usando solução matricial

Resposta:

- **Gradiente Descendente:** Algoritmo iterativo, ajusta os coeficientes em direção à minimização do erro, atualizando-os conforme a derivada do erro em relação a cada parâmetro.
- **Mínimos Quadrados (matricial):** Solução fechada (analítica) para os coeficientes:
$$\beta = (X^T X)^{-1} X^T y$$

Onde X é a matriz de features, y é o vetor de targets.
- O gradiente é útil para grandes datasets, ou quando não existe solução fechada (ex: regularização).

7) Como fazer um Feature Selection para um modelo de regressão linear e logística?

Resposta:

- **Métodos:** Forward selection, backward elimination, stepwise, regularização (Lasso), métricas de importância (ex: coeficientes ou p-value).
- **Critérios:** Significância estatística, impacto no erro preditivo, redução de multicolinearidade.
- **Na regressão logística:** Testar se variáveis contribuem para aumentar a AUC/ROC ou precisão, além de significância estatística.

8) Supondo que eu utilize uma Random Forest Feature Importance, como saber que as melhores Features da Random Forest serão as melhores para o Modelo de Regressão?

Resposta:

Não necessariamente as melhores features na Random Forest serão as melhores para regressão linear/logística, porque Random Forest captura interações e não linearidades, enquanto regressão linear depende de linearidade. O ideal é testar as features selecionadas em ambos os modelos ou usar técnicas específicas de seleção (p-values, regularização) para o modelo linear.

9) Qual a diferença entre Regularização Lasso e Ridge?

Resposta:

- **Ridge (L2):** Penaliza o quadrado dos coeficientes, encolhendo-os, mas não zera.
 - **Lasso (L1):** Penaliza o valor absoluto dos coeficientes, podendo zerar alguns, promovendo seleção de variáveis.
 - **Uso:** Lasso é útil para feature selection; Ridge para evitar overfitting mantendo todas as variáveis.
-

10) Supondo um estimador de Mínimos Quadrados solucionado por Matrizes, a solução usando Regularização Lasso e Ridge é um Sistema Possível Determinado ou Sistema Possível Indeterminado?

Resposta:

- **Ridge:** Sempre possui solução única (sistema possível determinado) porque adiciona λ à matriz, tornando-a invertível.
 - **Lasso:** Não garante solução única (pode ser indeterminado), pois a penalização L1 pode gerar múltiplas soluções, especialmente em presença de multicolinearidade.
-

11) Explique as melhores métricas para problemas de Regressão e quando utilizar cada uma delas, tanto em problemas de distribuição simétrica quanto em assimétrica

Resposta:

- **MSE/RMSE:** Penaliza erros grandes, sensível a outliers; preferível em distribuição simétrica.
- **MAE:** Penaliza todos os erros igualmente, robusto a outliers; ideal em distribuição assimétrica.
- **R²:** Mede proporção da variância explicada; útil para comparação entre modelos.
- **MAPE:** Percentual de erro, útil quando valores reais não são zero e interpretação percentual faz sentido.
- *Resumindo:* Se houver outliers ou assimetria, prefira MAE/mediana. Para dados normais/simétricos, MSE/RMSE.

12) Conforme eu incluo Features no Modelo de Regressão, meu R^2 sempre aumentará. Esse aumento é confiável e significa que o modelo está sempre melhorando?

Resposta:

O R^2 sempre aumenta com mais features, mas isso pode ser ilusório (overfitting).

O R^2 ajustado corrige esse problema, penalizando por quantidade de variáveis.

Mais features podem capturar apenas ruído, não sinal real.

- **Conclusão:** O aumento do R^2 não é garantia de melhora do modelo; use R^2 ajustado, validação cruzada e análise de erro fora da amostra para avaliar real ganho.

MODELOS DE ÁRVORE DE DECISÃO

1) Explique Árvore de Decisão simples passando pelo tipo de modelo, objetivo que ela busca atender, estimação da predição e estrutura hierárquica

Resposta:

Árvore de decisão é um modelo preditivo não paramétrico, utilizado tanto para classificação quanto regressão. Organiza decisões de forma hierárquica, onde cada nó interno representa um teste em uma feature, cada galho representa um resultado desse teste, e cada folha representa uma predição (classe ou valor).

- **Objetivo:** Maximizar pureza nas folhas, separando dados da melhor forma possível.
- **Predição:** Dada uma nova amostra, percorre-se a árvore seguindo os splits até uma folha.
- **Estimação:** Feita por algoritmos como CART, que escolhem splits maximizando métricas como Gini, Entropia (classificação) ou redução de variância (regressão).

2) Como a árvore decide o ponto ideal de corte de uma variável numérica?

Resposta:

A árvore avalia todos os possíveis pontos de corte (thresholds) para cada feature numérica, buscando o split que maximiza o ganho de pureza (ex: maior redução de Gini/entropia para classificação, menor variância para regressão).
Seleciona o ponto onde ocorre a maior separação entre classes ou maior redução do erro.

3) Pensando na estrutura hierárquica de uma Árvore com 5 níveis, qual das Features é a que melhor separa as classes?

Resposta:

A feature usada na raiz (primeiro split) é, em geral, a que melhor separa as classes globalmente, pois é responsável pela maior redução de impureza.
Em árvores profundas, splits posteriores refletem refinamentos locais e não necessariamente maior poder preditivo global.

4) Como eliminar Overfitting de uma Árvore de Decisão e os 3 principais hiperparâmetros do modelo para isso

Resposta:

Overfitting ocorre quando a árvore fica muito complexa, ajustando-se demais ao ruído dos dados.

Principais hiperparâmetros para controlar isso:

1. **max_depth:** Profundidade máxima da árvore.
 2. **min_samples_split:** Número mínimo de amostras para um nó ser dividido.
 3. **min_samples_leaf:** Número mínimo de amostras em uma folha.
- Outros: pruning (poda), max_features, regularização.
-

5) O que exatamente é uma Poda em uma Árvore de Decisão e como garantir que ela está impondo viés ao modelo

Resposta:

Poda (pruning) é o processo de remover ramos da árvore após o treinamento para evitar overfitting, simplificando a árvore.

- **Viés:** Ao podar, reduz-se a variância do modelo, mas aumenta o viés (modelo menos flexível). Avalia-se esse trade-off via validação cruzada.
-

6) A Árvore é impactada por Outliers ao longo do processo nos Nós e nas Folhas em um problema de Regressão?

Resposta:

Sim, árvores de decisão de regressão podem ser sensíveis a outliers porque usam a média dos valores em cada folha, e outliers podem distorcer esse valor.

- **Solução:** Limitar profundidade, usar mínimo de amostras por folha, ou usar medianas ao invés de médias em folhas.

7) Qual a principal diferença da predição de uma Árvore para uma Regressão Logística

Resposta:

- **Árvore de decisão:** Faz previsões discretas por splits sucessivos (modelo não linear, não paramétrico).
- **Regressão logística:** Modelo paramétrico, calcula probabilidade de classe com função logística.
Árvores capturam relações não lineares, interações complexas; regressão logística assume relação linear no logit.

8) Explique o que é Calibração, quando ela é importante e dois métodos para realizar a Calibração

Resposta:

Calibração refere-se ao alinhamento entre as probabilidades previstas por um modelo e as probabilidades reais observadas.

- **Importância:** Fundamental em aplicações onde a confiança do score importa (ex: risco de crédito, medicina).
- **Métodos:** Platt Scaling (regressão logística sobre as probabilidades), Isotonic Regression.

9) Quais são as melhores métricas para um problema de Classificação no que tange a capacidade preditiva do modelo e a qualidade do score

Resposta:

- **Capacidade preditiva:** Accuracy, F1-score, ROC AUC, Precision, Recall, MCC.
- **Qualidade do score:** Brier Score (calibração), Log Loss.
- Métrica ideal depende do contexto (balanceamento das classes, custo de falsos positivos/negativos).

10) Em um problema desbalanceado, a mudança no Threshold de Probabilidade e do Class Weight afeta de qual maneira as métricas de Precision e Recall? Quando optar por maximizar uma métrica em detrimento da outra?

Resposta:

- **Threshold:** Reduzindo o threshold, aumenta recall (mais positivos capturados) e diminui precision (mais falsos positivos).
- **Class Weight:** Penaliza mais o erro em classes minoritárias, ajudando a aumentar recall dessas classes.
- **Quando priorizar:** Se custo de falso negativo é alto (ex: fraude, saúde), maximize recall. Se custo de falso positivo é alto, maximize precision.

11) AUC e Gini são impactados pelo Threshold de Probabilidade?

Resposta:

Não. AUC (área sob a curva ROC) e Gini são métricas que avaliam performance do modelo independentemente do threshold de decisão, pois consideram todos os possíveis thresholds.

PRÉ-PROCESSAMENTO E VALIDAÇÃO EM GERAL

1) Me explique Cross Validation Cross Section e em Painel

Resposta:

- **Cross Validation Cross Section:** Tradicional, divide os dados em K-folds aleatórios, útil para dados i.i.d. (independentes e identicamente distribuídos).
- **Em Painel:** Em dados em painel (séries temporais por indivíduo), o split deve respeitar estrutura temporal e de painel, evitando "leak" de informação do futuro.
- Exemplo: Leave-one-group-out, blocos de tempo, ou cross-validation aninhada por painel.

2) Explique como fazer um Split correto pensando em um intervalo de 1 ano e obrigatoriamente usando Cross Validation e Out-Of-Sample

Resposta:

- Separar dados de treino e teste respeitando o tempo (ex: treina até 2023, testa em 2024).
- Dentro do treino, aplicar cross-validation (ex: K-fold temporal).
- O out-of-sample é sempre o último período (realmente nunca visto).
- Evita-se "leakage" e garante avaliação realista da generalização do modelo.

3) Supondo que você tenha um modelo intermediário dentro do Cross Validation com performance superior aos demais, você levaria esse modelo para produção?

Resposta:

Não imediatamente. O ideal é escolher o modelo com desempenho mais estável e consistente, não apenas um fold com melhor resultado (pode ser sorte/overfitting).

- **Prática:** Avaliar média/desvio padrão das métricas nos folds; evitar escolher por outlier de performance.

4) Qual a importância de uma Target estável e não caótica ao longo do tempo e como garantir que o Modelo não está overfittando ao longo do tempo

Resposta:

- **Target estável:** Facilita modelagem, garante que padrões aprendidos são replicáveis no futuro.
- **Overfitting temporal:** Validar o modelo sempre fora da amostra, monitorar performance ao longo do tempo, recalibrar periodicamente.
- Monitorar conceito de “concept drift”.

KMEANS

1) Explique o que é o KMEANS e os problemas que ele pode apresentar

Resposta:

KMeans é um algoritmo de clusterização não supervisionada que particiona dados em K grupos, minimizando a soma das distâncias quadradas entre pontos e centroide do cluster.

Problemas:

- Sensível a outliers.
- Precisa definir K previamente.
- Converge para mínimos locais.
- Assume clusters esféricos e de tamanho similar.

2) Como escolher o número ideal de Clusters?

Resposta:

- **Métodos comuns:** Elbow Method (analisar WCSS vs. K), Silhouette Score, Gap Statistic.
- **Prática:** Procurar ponto onde acréscimo de K traz ganho marginal pequeno (cotovelo).

3) Supondo que o problema admita N Clusters diversos, sem um limite específico ou necessidade de explicabilidade, qual a relação entre o WCSS e o Silhouette Score para a escolha do número ideal? Além disso, explique como ambas são criadas e como podemos interpretá-las

Resposta:

- **WCSS (Within-Cluster Sum of Squares):** Soma das distâncias quadradas dos pontos aos centróides. Diminui com mais clusters. Usado no método do cotovelo.
- **Silhouette Score:** Mede quão próximo cada ponto está de seu cluster em comparação com outros clusters. Varia de -1 (mal agrupado) a 1 (bem agrupado).
- **Interpretação:**
 - Elbow: ponto de inflexão.
 - Silhouette: maior valor médio é melhor.
- **Relação:** Usar ambos para balizar escolha de K, buscando equilíbrio entre compactação e separação dos clusters.

4) Como realizar a explicabilidade de Clusters da forma correta?

Resposta:

- Descrever características médias de cada cluster.
 - Utilizar gráficos (boxplot, radar, PCA para 2D).
 - Listar features discriminantes.
 - Se possível, associar clusters a perfis de negócio (ex: segmentação de clientes).
-